RECOMMENDATION SYSTEM

–

AMAZON FASHION 2023

DAVIDE DONEDDU 879365

Progetto Metodi Informatici per la Gestione Aziendale

IL DATASET “AMAZON FASHION” È STATO UTILIZZATO PER TUTTE LE FASI DI ANALISI E PREPARAZIONE DEI SISTEMI DI RACCOMANDAZIONE

Passi principali eseguiti e presentati nelle slide successive

- Analisi Esplorativa
- Pulizia dei dataset
- Collaborative Filtering KNN
- Clustering Utenti
- Content Based
- Sentiment Analysis
- Conclusioni

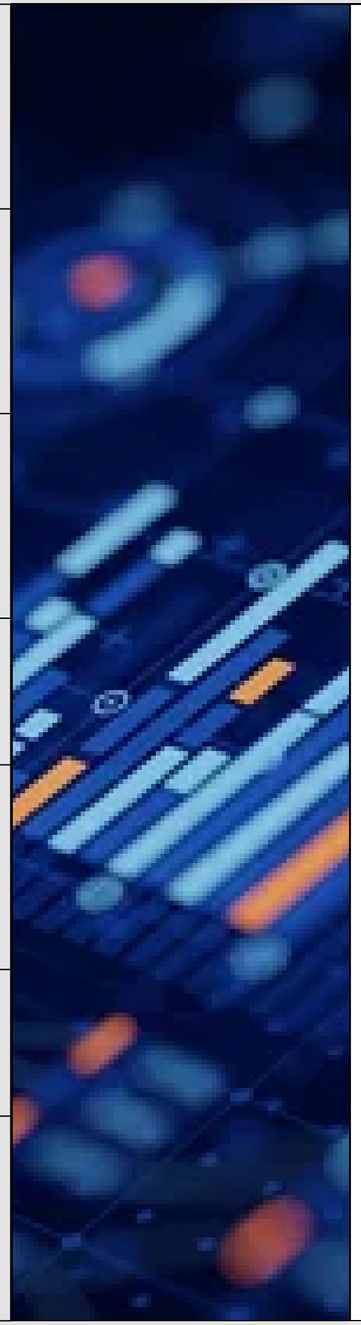

ANALISI ESPLORATIVA

Quali informazioni fossero disponibili nel dataset e quali problemi di qualità dei dati fosse necessario individuare e affrontare

DATASET REWIEW

2.500.939 recensioni, 2.035.490 utenti, 874.297 sottoprodotti, 825.869 prodotti principali.
Colonne Utilizzate : Rating, Title, Text, Parent Asin, User Id.

Sparsità Originale : Prossima al 100%.
Sbilanciamento del rating fortemente verso il massimo
*(QUARTILI : min **1**, 25% **3**, 50% **5** 75% **5**, max **5**)*

DATASET METADATI PRODOTTI

826.108 prodotti descritti da 14 attributi.
Colonne rilevanti utilizzate: **parent_asin, title, description**

title : media: 14.3 parole, mediana: 14 parole, distribuzione tra 11 e 17 parole.
description: media: 6.0 parole, mediana 0 parole, 59.289 con descrizione non vuota.

Progetto MIGA 24/25 - Davide Doneddu

PULIZIA DEI DATASET E PREPARAZIONE ALLE FASI SUCCESSIVE

Per ovviare alla sparsità eccessiva e all'alto numero di coppie user-product, è stato applicato un filtro sul numero minimo di interazioni utente/prodotto applicato su entrambi:

- almeno 3 interazioni per utente;
- almeno 5 interazioni per prodotto.

Le statistiche sui dataset filtrate sono:

- Utenti 967
- Prodotti 572
- Rating osservati 4,849
- Dimensione matrice 553,124
- Sparsità 99.12%
- Media parole : title 14,5 description 4.2 parole (metadata
- Media prezzo 26,9 $

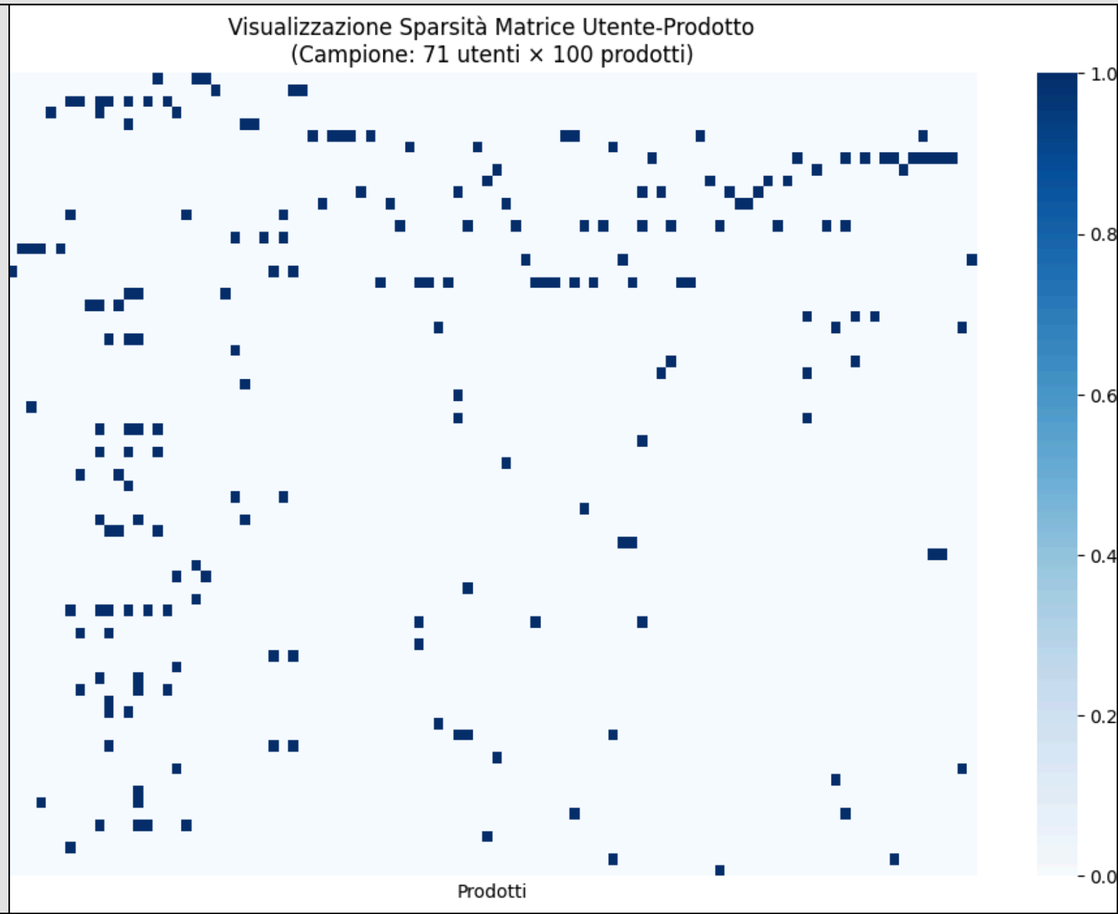

COLLABORATIVE FILTERING

Creazione Matrice CSR

La matrice viene generata in formato CSR mettendo il **rating specifico** se esiste per la coppia utente prodotto altrimenti **0**

La separazione del train e test set è stata eseguita dividendo la matrice in **80% train e 20% test.**

Configurazione Ottimale KNN e Filling

La configurazione ottimale ricercata tramite "Grid Search":
(**similarità**: cosine, Pearson, **modalità**: user-based e item-based, **k**: 5, 10, 20, 30, 40, 60, 80, 100)

Il filling è stato effettuato usando la configurazione :
(**similarità**: cosine, **modalità**: user-based, **k**: 10)

Matrix Factorization SVD

E' stato utilizzato SVD con k = 50 fattori latenti

Confronto Finale

KNNBaseline : RMSE 1.0626 MSE 1.1291.
SVD: RMSE 1.0254, MSE 1.0515
SVD migliora di circa il **3,5%** l'accuratezza delle raccomandazioni

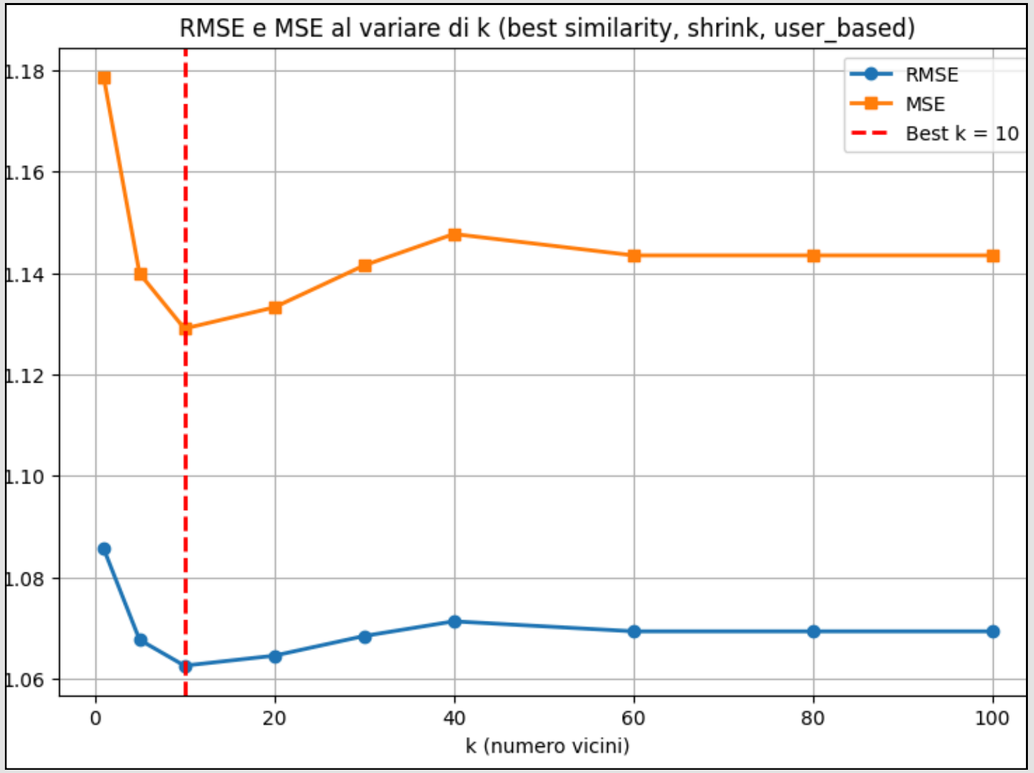

CLUSTERING UTENTI

Sulla matrice è stato applicato PCA mantenendo le prime 20 componenti principali.

Successivamente tramite “Elbow Method” (con l’auto del “Silhouette Score”) è stato identificato il numero ottimale (6) di cluster.

Infine è stato applicato k-means identificando i seguenti:

Cluster 0 – Utenti equilibrati con valutazioni variabili e bassa attività.
Cluster 1 – Utenti molto positivi con pochi rating.
Cluster 2 – Utenti positivi e moderatamente attivi.
Cluster 3 – Utenti mediamente positivi con giudizi eterogenei.
Cluster 4 – Utenti estremamente positivi e consistenti.
Cluster 5 – Utenti critici con valutazioni basse.

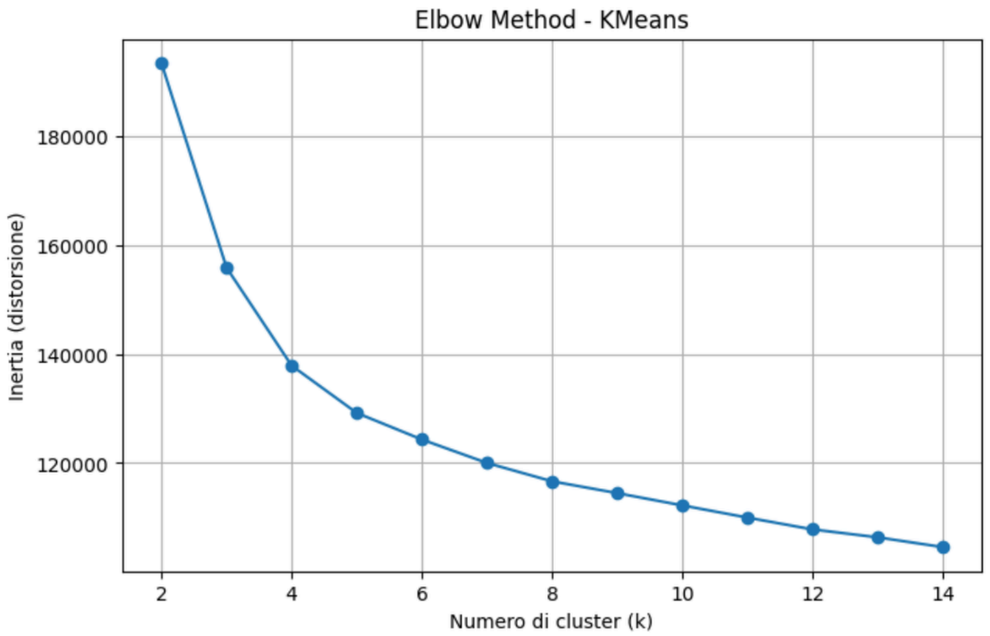

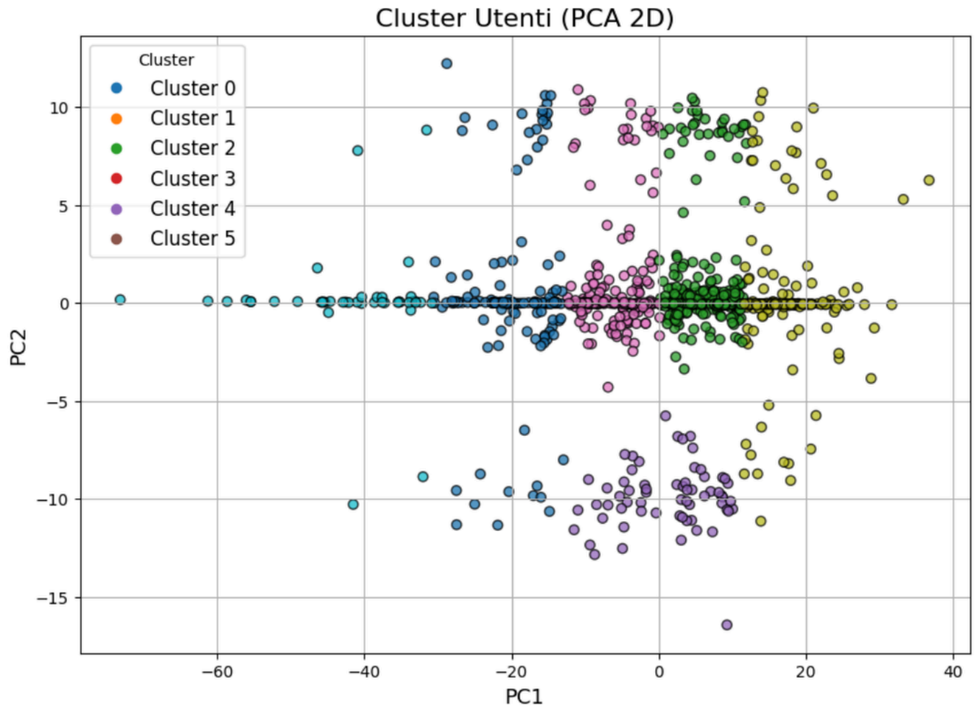

CONTENT BASED

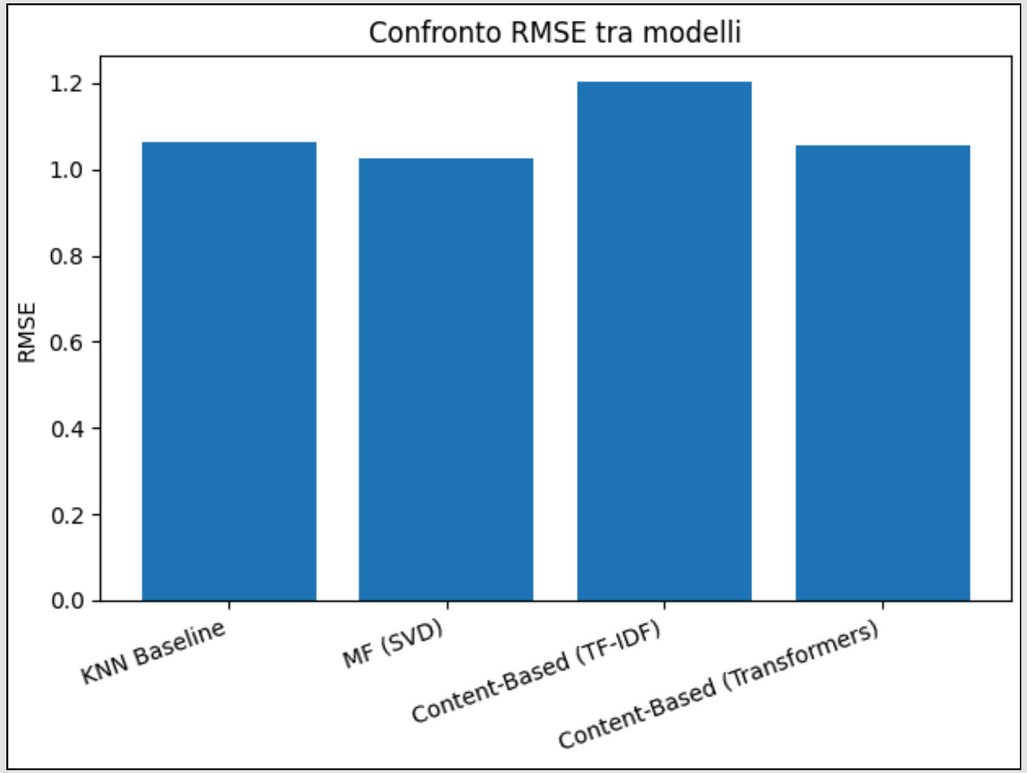

Preprocessing Attributi Testuali

Sono stati unificati il campo title e description per ogni prodotto.

La pipeline applicata per il prepocessing è stata:
to lower > rimozione punteggiatura simboli e cifre > tokenizzazione delle parole > rimozione delle stopwords > lemmatizzazione > rimozione descrizioni vuote

Generazione Embedding Testuali

TF-IDF : ricercando un massimo di 5000 feature (1189 trovate) che siano unigrammi o bigrammi e che non siano troppo rare (minimo 3 presenze).

TRASFORMERS su modello DistilBERTbase-NLI-Mean-Tokens : risulta in una shape di (572, 768) con vettori di 768 caratteristiche semantica latenti

TF-IDF vs Transformers : Predizioni

Capacità semantica: Transformers. **Robustezza descrizioni brevi**: Transformers
Differenze nel ranking: Transformers. **Costo computazionale**: TF-IDF

Confronto con il Collaborative Filtering

KNN Baseline (CF): RMSE = 1.0626, MAE = 0.7793
MF-SVD (CF): RMSE = 1.0254, MAE = 0.7690 (MIGLIOR RMSE)
Content-Based TF-IDF: RMSE = 1.2025, MAE = 0.7737 (PEGGIORE)
Content-Based Transformers: RMSE= 1.0572, MAE= 0.7128 (MIGLIOR MAE)

SENTIMENT ANALYSIS

Modellazione
Embedding del campo congiunto title+text delle recensioni con TF-IDF e Transformers
Applicazione della classificazione Random Forest (Balanced)

Confronto tra predizioni TF-IDF e Transformers

Metrica/Classe	TF-IDF	Transformers
Accuracy	0.859	0.850
Classe 0 : Precision Recall F1-Score	0.96, 0.52, 0.68	0.93, 0.45, 0.61
Classe 1 : Precision Recall F1-Score	0.93, 0.13, 0.23	0.92, 0.11, 0.20
Classe 2: Precision Recall F1-Score	0.85, 1, 0.92	0.85, 1, 0.92
F1-score (weighted)	0.82	0.81

GRAZIE

Progetto MIGA 24/25 - Davide Doneddu